Self-Supervised Learning en Neuroimagen: Detección de Gliomas mediante Aprendizaje Contrastivo sobre BRATS

Alejandro Cuevas · **Iria Lozano** · **Javier Saguar**

Procesado Avanzado de Señales y Datos (PASD)
Escuela Técnica Superior de Ingenieros de Telecomunicación
Universidad Politécnica de Madrid

Resumen

Implementamos un pipeline completo de aprendizaje contrastivo (SimCLR) para la detección de gliomas en resonancia magnética cerebral multimodal (BRATS, 484 pacientes, 4 modalidades). Con solo 20 pacientes etiquetados, nuestro método obtiene **AUC-ROC 0.9303**, superando a todos los métodos supervisados comparados. Con el dataset completo (484 pacientes) obtenemos **AUC-ROC 0.8945** (validación estadística: $0{,}9068 \pm 0{,}0276$, 5 runs). El trabajo evidencia que el aprendizaje contrastivo es el método óptimo en escenarios clínicos con datos etiquetados escasos.

Blog de la Asignatura PASD · Mayo 2025

Índice

1. Introducción **2**

2. Estado del arte **2**

3. Fundamentos matemáticos **2**
3.1. Normalización Z-score . . . 2
3.2. Similitud coseno . . . 3
3.3. NT-Xent Loss . . . 3
3.4. Coeficiente de silueta . . . 3

4. Materiales **3**
4.1. Dataset BRATS . . . 4
4.2. Entorno de desarrollo . . . 4

5. Desarrollo **4**
5.1. Etapa 1 — Preentrenamiento contrastivo (SimCLR) . . . 4
5.2. Etapa 2 — Fine-tuning para clasificación . . . 5

6. Resultados **5**
6.1. Entrenamiento contrastivo . . . 5
6.2. Efecto del preentrenamiento contrastivo . . . 5
6.3. Clasificación final . . . 6
6.4. Comparativa con métodos supervisados . . . 6

7. Discusión **6**

8. Conclusiones **7**

Referencias **7**

Materiales **7**

1. Introducción

El diagnóstico de tumores cerebrales mediante resonancia magnética (RM) es una tarea clínica de alta complejidad que exige interpretar simultáneamente múltiples secuencias de imagen. Los gliomas, el tipo de tumor cerebral primario más frecuente, presentan subregiones con morfología e intensidad de señal muy distintas según la modalidad empleada. Sin embargo, el etiquetado manual por parte de radiólogos expertos es costoso, lento y escaso, lo que limita la disponibilidad de datos etiquetados para entrenar modelos supervisados.

El aprendizaje contrastivo ofrece una solución natural: aprender representaciones ricas del espacio latente usando únicamente datos no etiquetados, para luego transferirlas a tareas clínicas con muy pocos ejemplos supervisados. La clave está en que, en lugar de decirle al modelo qué es cada imagen, le enseñamos qué imágenes son similares entre sí. En este trabajo aplicamos SimCLR [**?**] sobre el dataset BRATS [**?**] y comparamos su rendimiento frente a métodos supervisados clásicos y de deep learning.

2. Estado del arte

El aprendizaje contrastivo fue formalizado por Chen et al. en SimCLR [**?**], demostrando que maximizar la similitud entre vistas aumentadas del mismo dato —y minimizarla entre datos distintos— permite aprender representaciones de calidad comparable a métodos supervisados. Posteriormente, He et al. propusieron MoCo [**?**], introduciendo una cola de memoria que hace el entrenamiento más eficiente con batches pequeños. Más recientemente, VICReg [**?**] eliminó la necesidad de pares negativos mediante regularización de varianza, invarianza y covarianza.

En imagen médica, Azizi et al. [**?**] demostraron que modelos preentrenados con aprendizaje autosupervisado superan a los entrenados supervisadamente en clasificación médica con datos limitados. Chaitanya et al. [**?**] extendieron el aprendizaje contrastivo a segmentación médica con anotaciones parciales. El dataset BRATS [**?**, **?**] se ha consolidado como benchmark estándar para segmentación y clasificación de gliomas, con cuatro modalidades complementarias que capturan distintas propiedades del tejido tumoral.

3. Fundamentos matemáticos

3.1. Normalización Z-score

Para la estandarización de datos, aplicamos el z-score canal a canal sobre cada corte axial. Dado un valor individual x:

$$\hat{x} = \frac{x - \mu}{\sigma} \tag{1}$$

donde μ es la media del canal, σ su desviación estándar y $\hat{x}$ la puntuación estandarizada. Esta transformación garantiza que cada modalidad (FLAIR, T1w, T1gd, T2w) contribuya por igual al aprendizaje, independientemente de su rango de intensidad original.

3.2. Similitud coseno

Para medir el parecido entre representaciones en el espacio latente usamos la similitud coseno, que es robusta frente a cambios de brillo o contraste propios de la RM:

$$\text{sim}(u, v) = \frac{u^\top v}{\|u\| \cdot \|v\|} \tag{2}$$

A diferencia de la distancia euclídea, la similitud coseno se centra únicamente en la *dirección* del vector, ignorando su magnitud.

3.3. NT-Xent Loss

Para el preentrenamiento contrastivo implementamos la función de pérdida **NT-Xent** (Normalized Temperature-scaled Cross Entropy), propuesta en SimCLR [**?**]. Dado un par positivo de representaciones (z_i, z_j) provenientes de dos vistas aumentadas del mismo corte:

$$\ell_{i,j} = -\log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k=1}^{2N} \mathbf{1}_{[k \neq i]} \exp(\text{sim}(z_i, z_k)/\tau)} \tag{3}$$

donde $\tau = 0{,}5$ es el parámetro de temperatura y N el tamaño de batch. La temperatura controla la "dureza" de la distribución: valores bajos hacen el entrenamiento más selectivo, penalizando más los negativos difíciles.

3.4. Coeficiente de silueta

Para evaluar la calidad del clustering en el espacio latente *sin usar etiquetas*, empleamos el coeficiente de silueta. Dado un punto i:

$$s(i) = \frac{b(i) - a(i)}{\text{máx}\{a(i),\, b(i)\}} \tag{4}$$

donde $a(i)$ es la distancia media entre i y los demás puntos de su mismo cluster (cohesión), y $b(i)$ la distancia media mínima al cluster más cercano (separación). Valores próximos a 1 indican clusters bien separados.

Durante el preentrenamiento contrastivo el modelo aprende **sin etiquetas**. El coeficiente de silueta es la única forma de evaluar si el encoder ha aprendido estructura discriminativa de forma no supervisada: si los cortes con y sin tumor forman grupos naturalmente separados en el espacio latente, el aprendizaje contrastivo ha sido efectivo.

4. Materiales

4.1. Dataset BRATS

El dataset BRATS (Brain Tumour Segmentation Challenge) [**?**, **?**] contiene 484 pacientes con gliomas en formato NIfTI, con volúmenes de dimensiones $240 \times 240 \times 155$ vóxeles y cuatro modalidades de RM por paciente:

- **FLAIR**: elimina la señal del líquido cefalorraquídeo normal, resaltando el edema peritumoral.
- **T1w**: proporciona el mejor contraste anatómico de referencia.
- **T1gd**: resalta el tumor activo mediante contraste con gadolinio.
- **T2w**: destaca tejidos con alto contenido de agua (edema, necrosis).

Las máscaras de segmentación etiquetan cuatro regiones: fondo (label 0), edema peritumoral (label 1), tumor no realzado (label 2) y tumor realzado (label 3). El dataset es de acceso abierto a través del Medical Segmentation Decathlon[1].

Tras el preprocesado se obtuvieron **66.517 cortes 2D válidos** con distribución prácticamente equilibrada: 50.7 % con tumor y 49.3 % sin tumor.

4.2. Entorno de desarrollo

Componente	Configuración
Framework	Python 3.12, PyTorch 2.x
GPU	NVIDIA RTX 5070 Laptop (8.5 GB VRAM, CUDA 12.8)
Lectura NIfTI	nibabel
Preprocesado	scikit-image (resize con anti-aliasing)
Métricas	scikit-learn (AUC-ROC, F1, t-SNE, silueta)

Cuadro 1: Entorno de desarrollo empleado.

El código completo está disponible en el notebook del proyecto [enlace Drive].

5. Desarrollo

El pipeline se estructura en dos etapas bien diferenciadas: preentrenamiento contrastivo autosupervisado y fine-tuning supervisado.

5.1. Etapa 1 — Preentrenamiento contrastivo (SimCLR)

Se extrajeron cortes axiales 2D de cada volumen, descartando los vacíos (valor máximo $< 10^{-5}$) y aplicando el siguiente preprocesado por canal: clipping al percentil 99.5, normalización z-score y redimensionado a 128×128 píxeles.

Adaptamos **ResNet-50 preentrenada en ImageNet** (clasificación supervisada de 1000 clases de objetos — no un encoder contrastivo de origen) para aceptar 4 canales de entrada, inicializando el canal adicional con la media de los tres originales para preservar los pesos preentrenados. Se eliminó la capa de clasificación final y se añadió una projection head MLP ($2048 \to 512 \to 128$).

Para cada corte se generaron dos vistas aumentadas aplicando transformaciones estocásticas independientes: flips horizontal y vertical, rotación aleatoria $\pm 15°$, recorte aleatorio (escala

[1] http://medicaldecathlon.com/

80–100 %) y blur gaussiano. La NT-Xent Loss con temperatura $\tau = 0{,}5$ forzó al encoder a aprender representaciones similares para vistas del mismo corte y distintas para cortes diferentes, **sin usar ninguna etiqueta**.

Configuración de entrenamiento: 200 épocas, Adam (lr $= 10^{-3}$, weight_decay $= 10^{-4}$), CosineAnnealingLR ($T_{\max} = 200$). Checkpoints guardados cada 10 épocas.

5.2. Etapa 2 — Fine-tuning para clasificación

Sobre el encoder preentrenado se añadió una cabeza de clasificación ligera (2048 → 256 → 2, BatchNorm, ReLU, Dropout 0.3). El entrenamiento se realizó en dos fases:

1. **Encoder congelado**: 80 épocas, lr $= 3 \times 10^{-4}$, CosineAnnealingLR. Solo se actualizan los 525.570 parámetros de la cabeza.
2. **Encoder parcialmente descongelado**: layer3 y layer4 de ResNet-50, 80 épocas adicionales, lr $= 10^{-4}$ con CosineAnnealingLR.

Corrección metodológica aplicada. Una versión inicial empleaba `random_split` sobre los cortes individuales, introduciendo *data leakage*: cortes del mismo paciente podían aparecer simultáneamente en train y validación. El split correcto se realiza a nivel de **paciente**: todos los cortes de un paciente van al mismo split (387 train / 97 validación), garantizando la evaluación sobre cerebros completamente nuevos. Esta corrección redujo el AUC del prototipo de 0.99 a 0.92, resultado más honesto y generalizable.

6. Resultados

6.1. Entrenamiento contrastivo

Con 200 épocas sobre 484 pacientes la loss de entrenamiento alcanza 2.8755 (val loss: 3.3574), con una brecha train/val de 0.48 coherente con un split correcto por paciente. La curva de entrenamiento muestra convergencia sostenida a partir de la época 130, cuando el scheduler coseno reduce suficientemente el learning rate.

6.2. Efecto del preentrenamiento contrastivo

La comparativa de espacios latentes entre ResNet-50 original (silueta: 0.20) y el encoder SimCLR (silueta: 0.22) evidencia el valor del preentrenamiento contrastivo: la red reorganiza sus representaciones para capturar morfología cerebral en lugar de características de objetos de ImageNet, mejorando la separación emergente entre cortes con y sin tumor.

6.3. Clasificación final

Resultados finales — 484 pacientes (sin data leakage)

AUC-ROC	**0.8945**
F1-Score	**0.8168**
Accuracy	**81 %**
t-SNE Silueta	0.1718
Validación estadística (5 runs)	$0{,}9068 \pm 0{,}0276$

El clasificador obtuvo AUC-ROC 0.9246 con solo 20 pacientes etiquetados. La validación estadística con 5 runs y selección aleatoria de pacientes confirma la robustez del método.

6.4. Comparativa con métodos supervisados

Método	AUC (20 pac.)	AUC (484 pac.)	Etiquetas	Tiempo
SimCLR (nuestro)	**0.9303**	0.8945	Solo fine-tuning	∼600 min
ResNet-50 Supervisado	0.9195	0.9725	Todas	∼57 min
CNN desde cero	0.9277	**0.9798**	Todas	∼56 min
SVM + ResNet	0.8828	0.9431	Todas	∼25 min
RF + ResNet	0.8645	0.9333	Todas	∼1 min

Cuadro 2: Comparativa AUC-ROC entre SimCLR y métodos supervisados con 20 y 484 pacientes.

Con 20 pacientes, **SimCLR es el mejor método**, superando a todos los supervisados sin haber usado ninguna etiqueta durante el preentrenamiento. Con 484 pacientes los métodos supervisados ganan, lo que define el escenario óptimo de cada enfoque.

7. Discusión

Los resultados demuestran la viabilidad del aprendizaje contrastivo para detectar biomarcadores visuales en RM cerebral multimodal y, más importante, definen con precisión cuándo usarlo.

SimCLR es el método óptimo con datos escasos. Con 20 pacientes etiquetados obtiene AUC 0.93, superando a ResNet supervisada (0.92) y CNN desde cero (0.93) que necesitan todas las etiquetas. En el contexto clínico real, donde etiquetar volúmenes NIfTI requiere radiólogos especializados y horas de trabajo por caso, esta ventaja es decisiva.

Con suficientes datos, la supervisión directa gana. Con 484 pacientes la CNN desde cero alcanza AUC 0.98 frente al 0.89 de SimCLR. Resulta llamativo que la CNN sin preentrenamiento supere a ResNet supervisada: una posible explicación es que los sesgos de ImageNet dificultan la adaptación al dominio médico, mientras que la CNN aprende libremente la morfología cerebral.

Análisis de cortes similares. El experimento con cortes centrales ($Z = 60$–100) reveló un resultado contraintuitivo: filtrar los cortes más "informativos" *empeora* el AUC ($0{,}89 \rightarrow 0{,}78$) debido al desbalance extremo resultante (86 % con tumor). Esto confirma que la

heterogeneidad del dataset completo, aunque añade dificultad, es metodológicamente necesaria para un entrenamiento generalizable.

Como trabajo futuro: VICReg [?] o BYOL como alternativas más estables, ViT [?] para capturar dependencias globales, aumentaciones específicas para RM, y segmentación con cabeza U-Net sobre el encoder preentrenado.

8. Conclusiones

El aprendizaje contrastivo (SimCLR) es el método óptimo para la detección de biomarcadores en RM cerebral cuando los datos etiquetados son escasos: con 20 pacientes obtiene AUC 0.93, superando a todos los métodos supervisados. Con datos abundantes (484 pacientes), la supervisión directa resulta más eficiente. La validación estadística con 5 runs (AUC = 0,9068± 0,0276) confirma la robustez del método. El split correcto por paciente es imprescindible para evitar data leakage y obtener estimaciones fiables de generalización.

Referencias

[1] Chen, T., Kornblith, S., Norouzi, M., & Hinton, G. (2020). *A Simple Framework for Contrastive Learning of Visual Representations*. ICML 2020. https://arxiv.org/abs/2002.05709

[2] He, K., Fan, H., Wu, Y., Xie, S., & Girshick, R. (2020). *Momentum Contrast for Unsupervised Visual Representation Learning*. CVPR 2020. https://arxiv.org/abs/1911.05722

[3] Bardes, A., Ponce, J., & LeCun, Y. (2022). *VICReg: Variance-Invariance-Covariance Regularization for Self-Supervised Learning*. ICLR 2022. https://arxiv.org/abs/2105.04906

[4] Menze, B.H. et al. (2015). *The Multimodal Brain Tumor Image Segmentation Benchmark (BRATS)*. IEEE Transactions on Medical Imaging. https://doi.org/10.1109/TMI.2014.2377694

[5] Bakas, S. et al. (2017). *Advancing The Cancer Genome Atlas glioma MRI collections with expert segmentation labels*. Scientific Data. https://doi.org/10.1038/sdata.2017.117

[6] He, K., Zhang, X., Ren, S., & Sun, J. (2016). *Deep Residual Learning for Image Recognition*. CVPR 2016. https://arxiv.org/abs/1512.03385

[7] Dosovitskiy, A. et al. (2021). *An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale*. ICLR 2021. https://arxiv.org/abs/2010.11929

[8] Azizi, S. et al. (2021). *Big Self-Supervised Models Advance Medical Image Classification*. ICCV 2021. https://arxiv.org/abs/2101.05224

[9] Chaitanya, K. et al. (2020). *Contrastive Learning of Global and Local Features for Medical Image Segmentation*. NeurIPS 2020. https://arxiv.org/abs/2006.10511

[10] Van der Maaten, L., & Hinton, G. (2008). *Visualizing Data using t-SNE*. Journal of Machine Learning Research. https://jmlr.org/papers/v9/vandermaaten08a.html

Materiales

- Dataset BRATS: http://medicaldecathlon.com/
- Notebook del proyecto (Google Drive): [enlace]

- Notebook comparativa supervisada (Google Drive): [enlace]
- SimCLR (Google Research): https://github.com/google-research/simclr
- solo-learn (PyTorch): https://github.com/vturrisi/solo-learn
- PyTorch: https://pytorch.org/
- nibabel: https://nipy.org/nibabel/