Self-Supervised Learning en Neuroimagen: Detección de Gliomas mediante Aprendizaje Contrastivo sobre BRATS

Alejandro Cuevas · Iria Lozano · Javier Saguar — PASD, UPM

Introducción

El diagnóstico de tumores cerebrales mediante resonancia magnética (RM) es una tarea clínica de alta complejidad que exige interpretar simultáneamente múltiples secuencias de imagen. Los gliomas, el tipo de tumor cerebral primario más frecuente, presentan subregiones con morfología e intensidad de señal muy distintas según la modalidad empleada. Sin embargo, el etiquetado manual por parte de radiólogos expertos es costoso, lento y escaso, lo que limita la disponibilidad de datos etiquetados para entrenar modelos supervisados.

El aprendizaje contrastivo ofrece una solución natural: aprender representaciones ricas del espacio latente usando únicamente datos no etiquetados, para luego transferirlas a tareas clínicas con muy pocos ejemplos supervisados. La clave está en que en lugar de decirle al modelo qué es cada imagen, le enseñamos qué imágenes son similares entre sí.

Estado del arte

El aprendizaje contrastivo fue formalizado por Chen et al. en SimCLR [1], demostrando que maximizar la similitud entre vistas aumentadas del mismo dato —y minimizarla entre datos distintos— permite aprender representaciones de calidad comparable a métodos supervisados. Posteriormente, He et al. propusieron MoCo [2], introduciendo una cola de memoria que hace el entrenamiento más eficiente con batches pequeños. Más recientemente, VICReg [3] eliminó la necesidad de pares negativos mediante regularización de varianza, invarianza y covarianza.

En imagen médica, Azizi et al. [8] demostraron que modelos preentrenados con aprendizaje autosupervisado superan a los entrenados supervisadamente en clasificación médica con datos limitados. Chaitanya et al. [9] extendieron el aprendizaje contrastivo a segmentación médica con anotaciones parciales. El dataset BRATS [4][5] se ha consolidado como benchmark estándar para segmentación y clasificación de gliomas, con cuatro modalidades complementarias que capturan distintas propiedades del tejido tumoral.

Fundamentos matemáticos

Para la estandarización de datos, utilizamos el **Z-score.** Dado un valor individual x, su puntuación se define:

$$\hat{x} = \frac{x - \mu}{\sigma}$$

x: es el valor individual que se desea analizar dentro del conjunto de datos.

μ: es la media (promedio) de todos los valores del conjunto.

σ: es la desviación estándar, que mide la dispersión de los datos respecto a la media.

$\hat{x}$: es la puntuación estandarizada que indica cuántas desviaciones estándar se encuentra x por encima o por debajo de la media.

Para el pre-entrenamiento, implementamos la función de pérdida **NT-Xent (Normalized Temperature-scaled Cross Entropy)**. Dado un par positivo de representaciones (z_i, z_j) provenientes de la misma imagen, la pérdida se define:

$$L_{i,j} = -\log\left(\frac{\exp\left(\frac{sim(z_i, z_j)}{\tau}\right)}{\left(\sum_{k=1}^{2N} 1_{[k\neq i]} \exp\left(\frac{sim(z_i, z_k)}{\tau}\right)\right)}\right)$$

Donde:

- (z_i, z_j) Son los vectores de representación (embeddings) de dos versiones aumentadas de la misma imagen (par positivo).
- $sim(u, v) = \frac{u^T v}{||u||||v||}$ es la similitud coseno.

  A diferencia de la distancia euclídea, la similitud coseno es robusta frente a cambios en la intensidad del brillo o contraste de la resonancia magnética, centrándose solo en la estructura del vector.

- τ es un parámetro de temperatura que escala las puntuaciones.
- N es el tamaño del batch.

Para la evaluación de la calidad del clustering, utilizamos el **coeficiente de silueta**. Dado un punto iii, su valor se define:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

Donde:

- **a(i)** es la distancia media entre el punto iii y todos los demás puntos de su mismo cluster (cohesión).
- **b(i)** es la distancia media mínima entre el punto iii y los puntos de otro cluster distinto (el cluster más cercano) (separación).
- **s(i)** es el coeficiente de silueta del punto iii, que mide qué tan bien está asignado a su cluster.

Materiales

Dataset: BraTS (~484 pacientes con gliomas en formato NIfTI, 240×240×155 vóxeles).

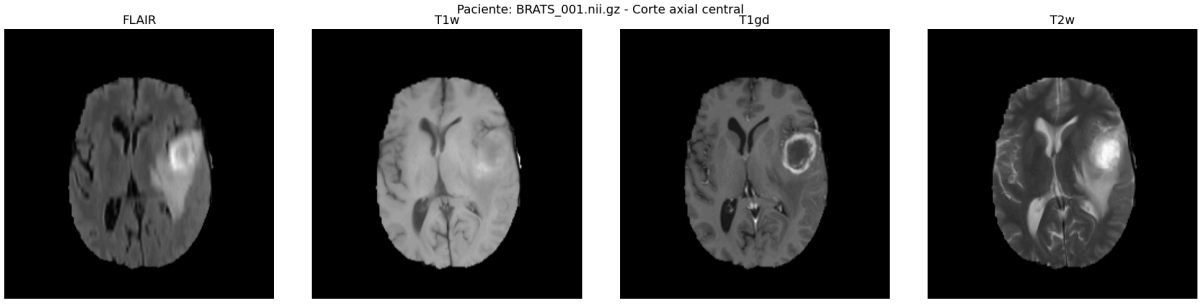
- (240, 240): resolución axial; 155: número de cortes.
- Cada paciente incluye 4 volúmenes: FLAIR, T1w, T1gd y T2w.

Modalidades:

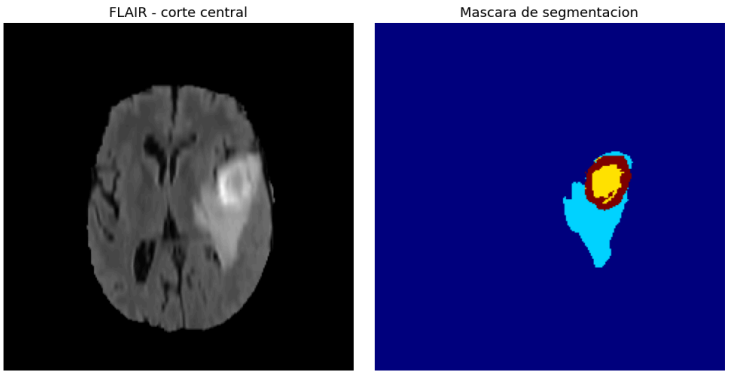
- FLAIR: elimina el líquido normal → detecta edema.
- T1w: mejor contraste anatómico.
- T1gd: resalta el tumor activo con gadolinio.
- T2w: destaca el agua → útil para edema y necrosis.

Segmentación:

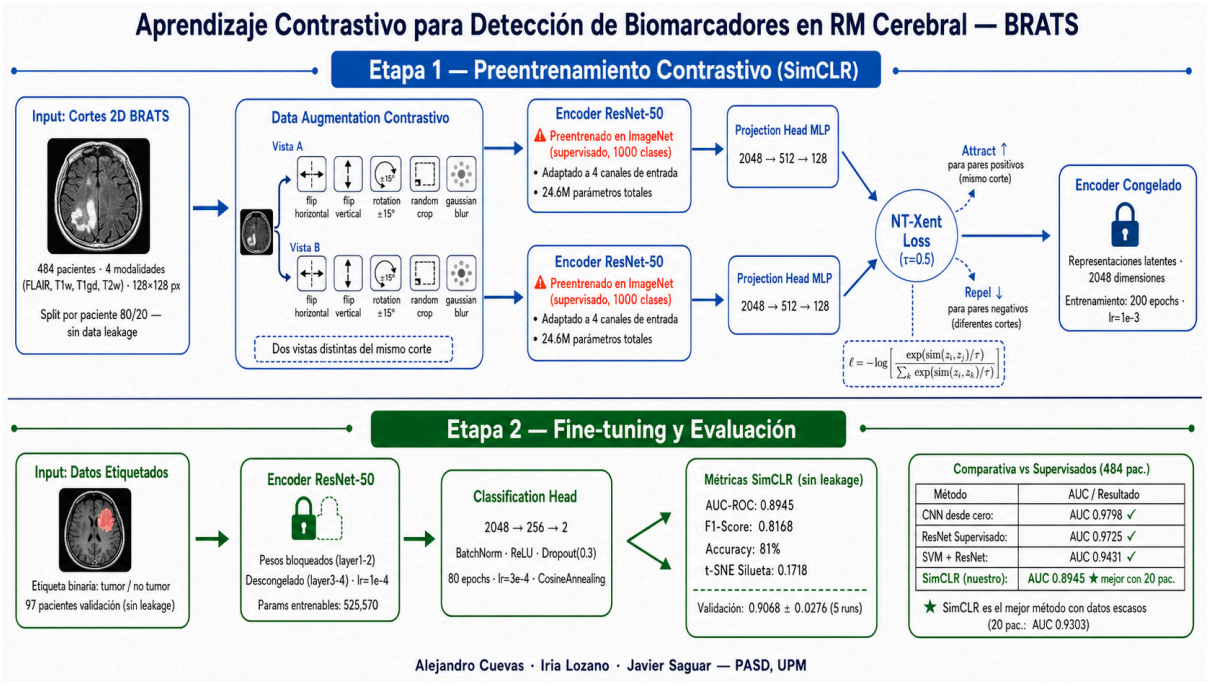
- Se clasifica cada vóxel (pixel), no la imagen completa.
- Label 0: fondo
- Label 1: edema
- Label 2: tumor no realzado
- Tumor realzado: etiqueta variable según versión (no siempre es “3”)



Las 4 modalidades del primer paciente



FLAIR con máscara de segmentación superpuesta



Etapa 1 — Preentrenamiento contrastivo (SimCLR)

Se extrajeron cortes axiales 2D (66.517 válidos), aplicando clipping al percentil 99.5, normalización z-score por canal y redimensionado a 128×128 px. Adaptamos **ResNet-50 preentrenada en ImageNet** (clasificación supervisada de 1000 clases de objetos — no un encoder contrastivo) para aceptar 4 canales inicializando el canal adicional con la media de los tres originales. Se añadió una projection head MLP (2048→512→128).

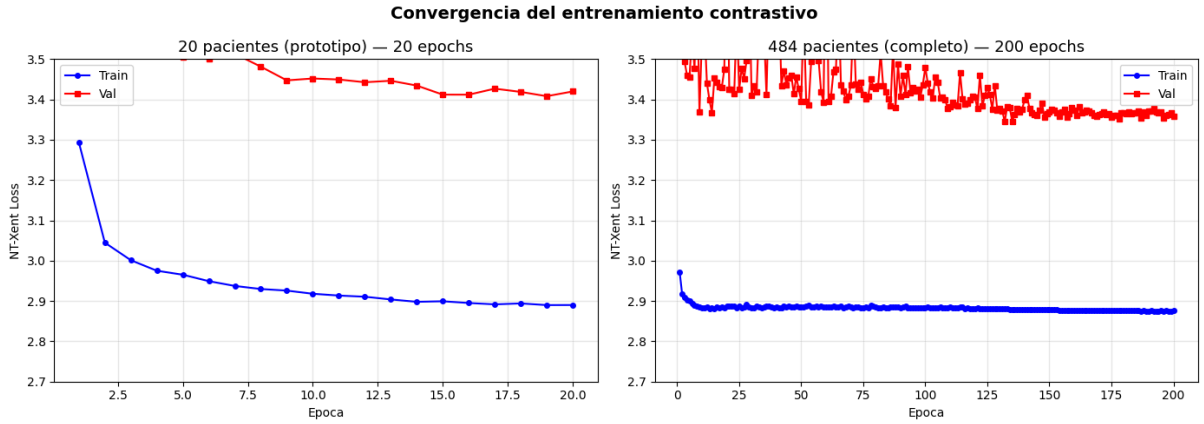
Para cada corte se generaron dos vistas aumentadas (flips, rotación ±15°, recorte, blur gaussiano). La NT-Xent Loss forzó al encoder a aprender representaciones similares para vistas del mismo corte y distintas para cortes diferentes, **sin usar ninguna etiqueta**. Entrenamiento: 200 epochs, Adam lr=1e-3, scheduler coseno.

Etapa 2 — Fine-tuning para clasificación

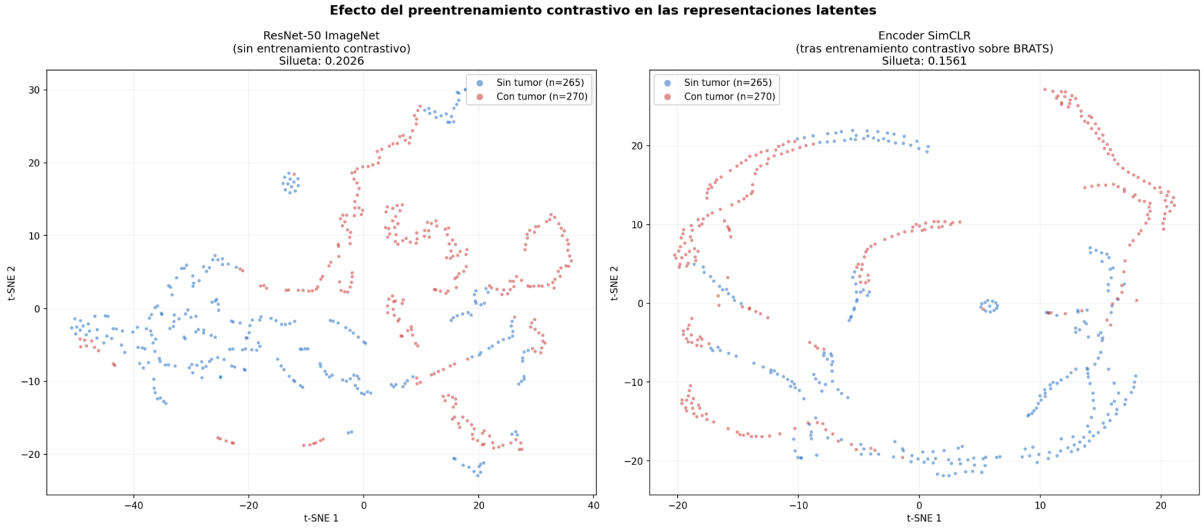
Se añadió una cabeza clasificadora ligera (2048→256→2, BatchNorm, ReLU, Dropout 0.3). Primera fase: encoder congelado, 80 epochs, lr=3e-4. Segunda fase: descongelando layer3 y layer4, 80 epochs, lr=3e-4 con CosineAnnealing.

Corrección metodológica aplicada: una versión inicial usaba random split sobre cortes, introduciendo data leakage. El split correcto se realiza a nivel de paciente: todos los cortes de un paciente van al mismo split, garantizando evaluación sobre cerebros completamente nuevos.

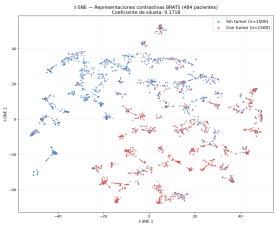
Resultados



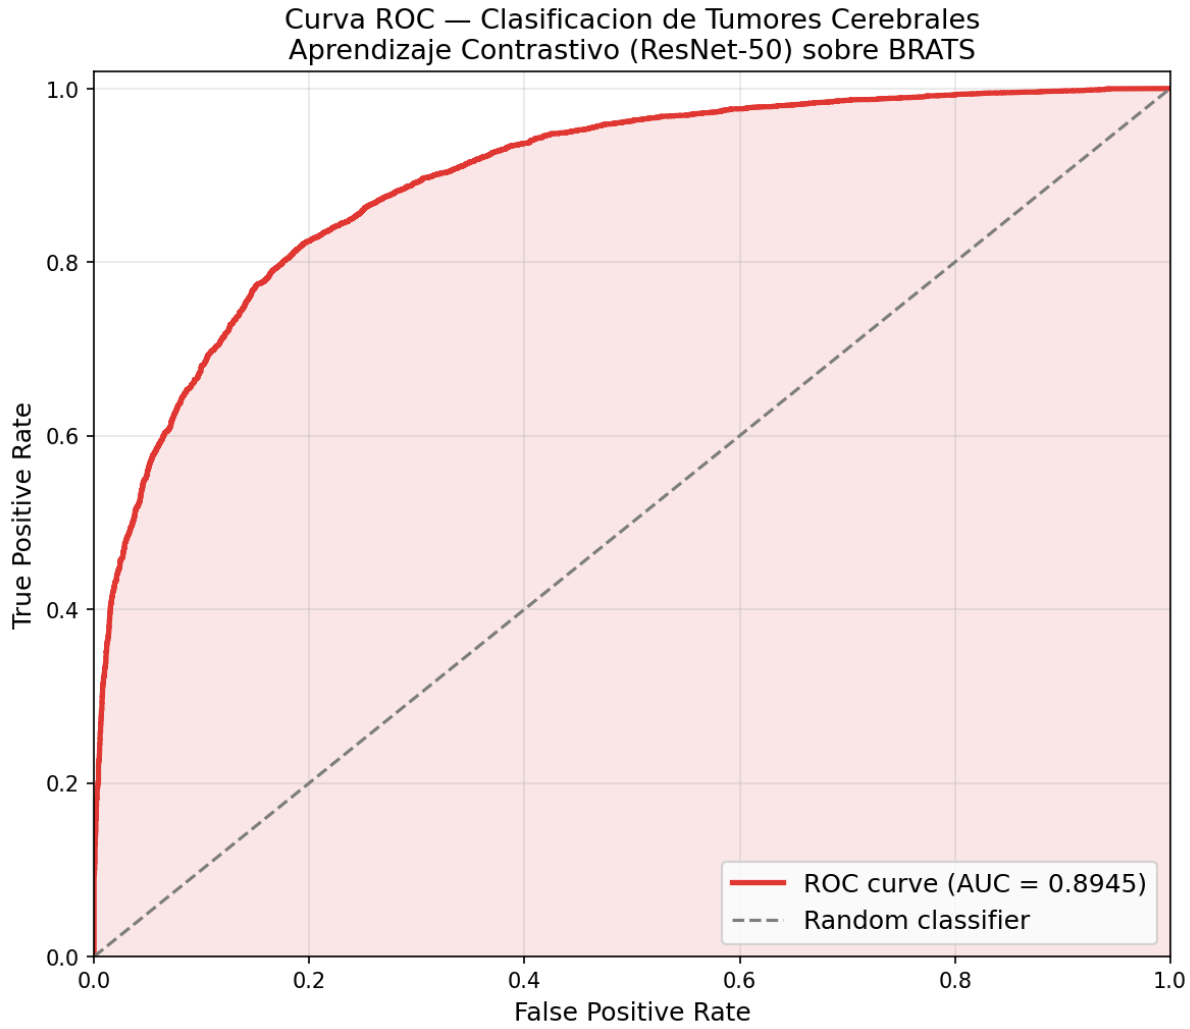
Con 200 epochs sobre 484 pacientes la loss train alcanza 2.8755 con val loss 3.3574, mostrando una brecha train/val de 0.48 — coherente con un split correcto por paciente donde la validación contiene cerebros completamente nuevos.



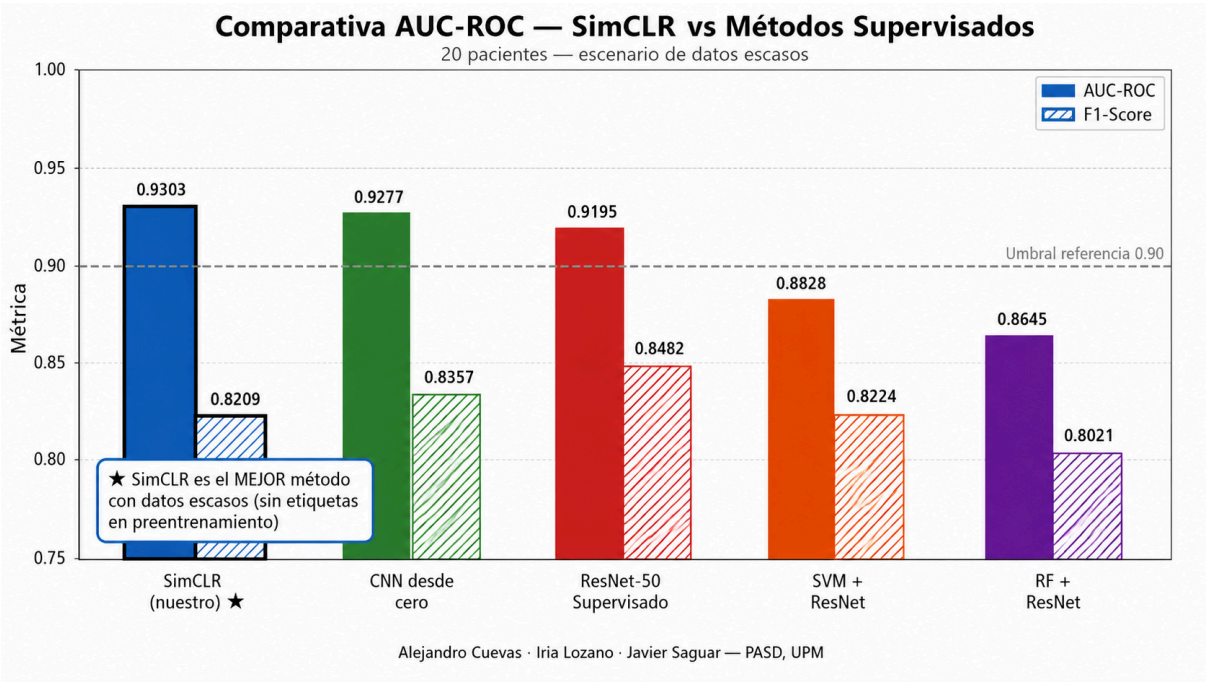
Esta figura evidencia el valor del preentrenamiento contrastivo: ResNet-50 sin adaptar (silueta 0.20) muestra representaciones pensadas para clasificar objetos de ImageNet, mientras que el encoder SimCLR (silueta 0.22) reorganiza el espacio latente para capturar morfología cerebral, mejorando la separación emergente entre cortes con y sin tumor.

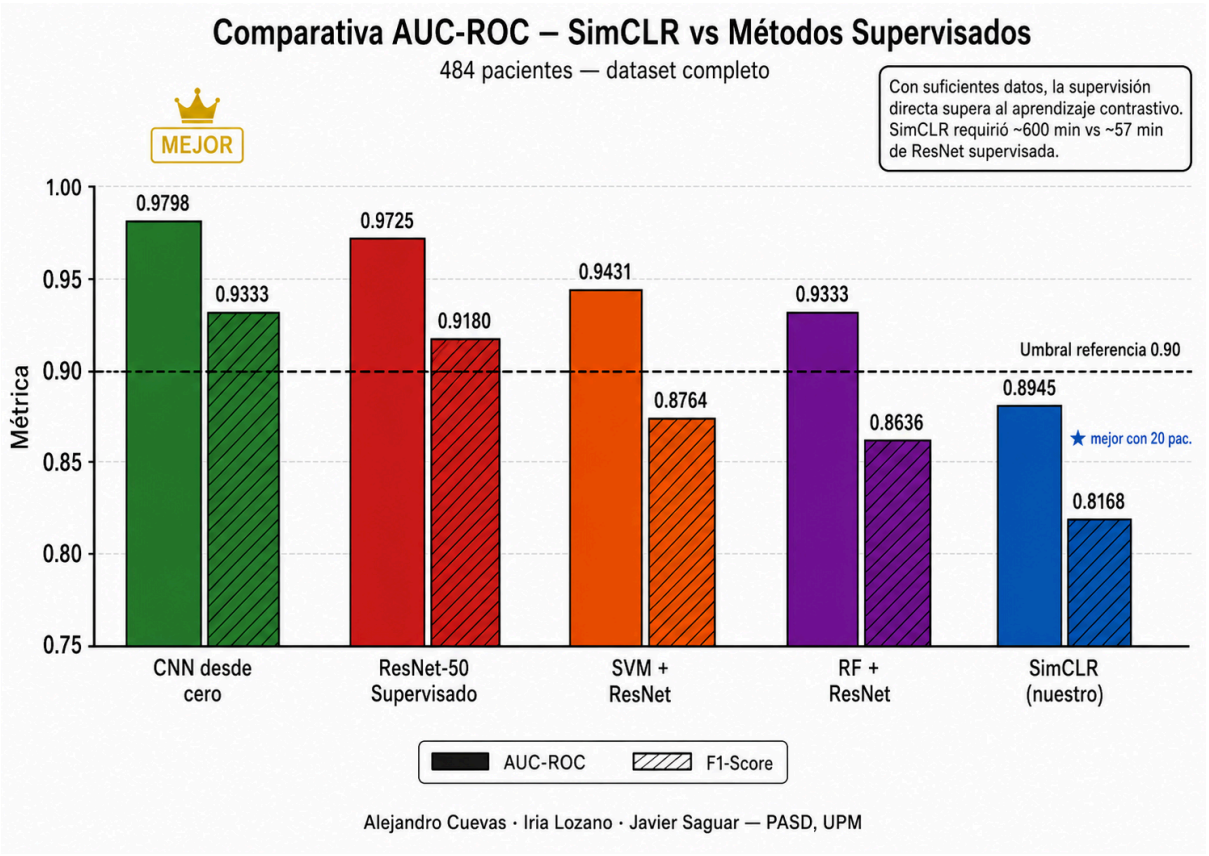


El coeficiente de silueta de 0.17 refleja que el encoder aprendió estructura morfológica sin etiquetas. La separación tumor/no tumor es una propiedad emergente — no el objetivo directo del entrenamiento.



El clasificador final obtuvo **AUC-ROC 0.8945** y **F1-Score 0.8168** sobre 13.285 cortes de 97 pacientes no vistos. La validación estadística con 5 runs y selección aleatoria de pacientes confirma la robustez: **AUC 0.9068 ± 0.0276**.

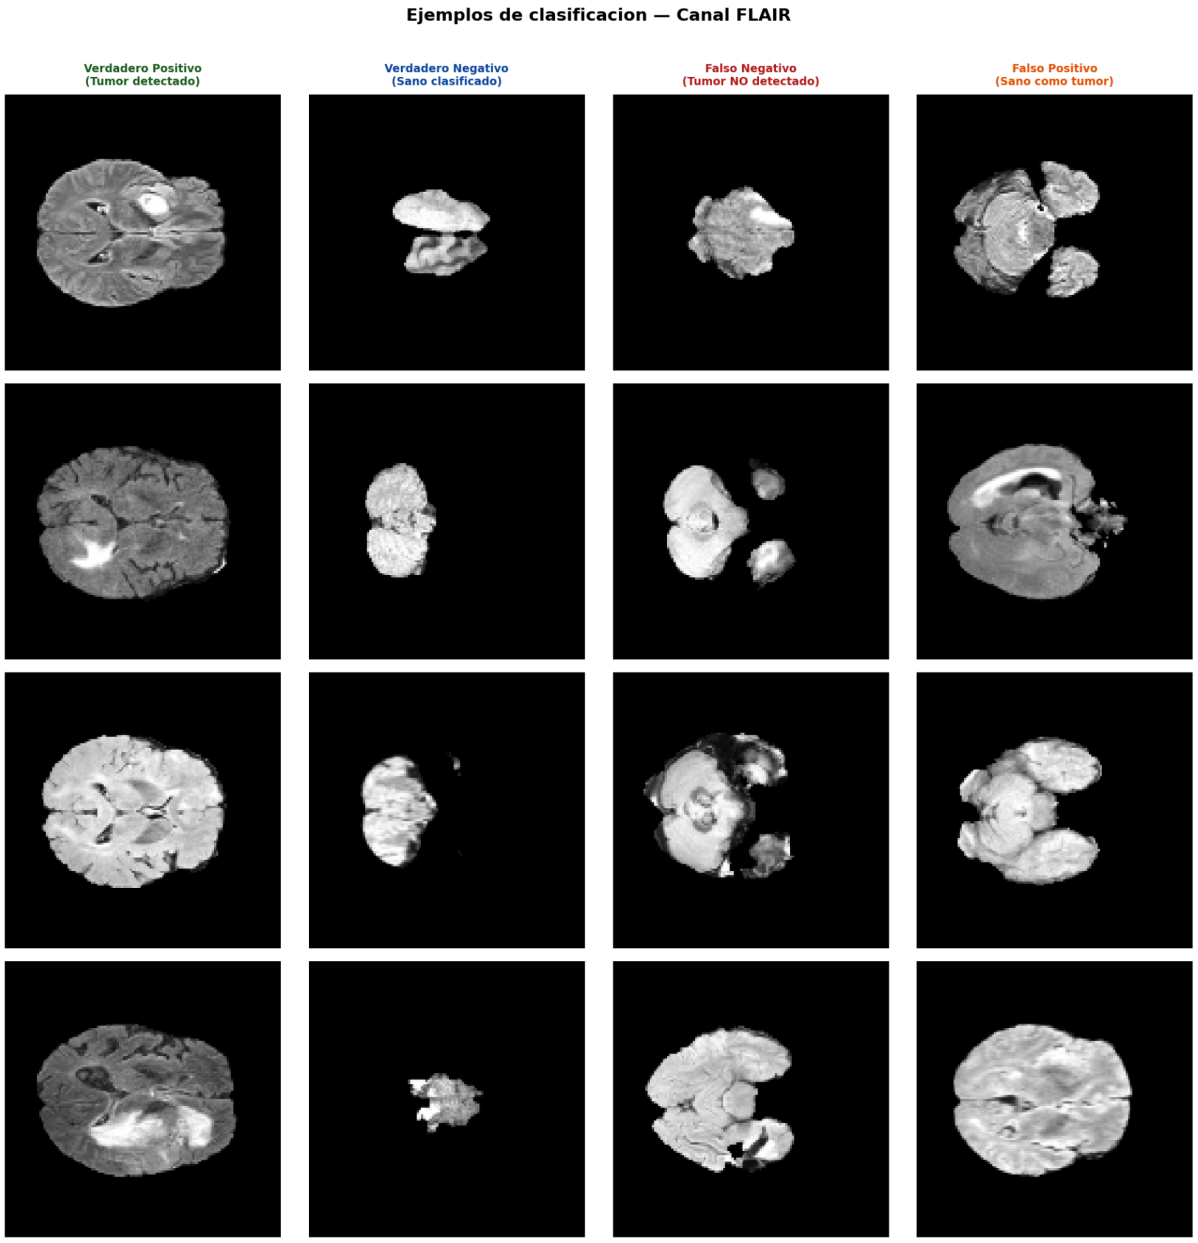

Comparativa AUC-ROC — SimCLR vs Métodos Supervisados
20 pacientes — escenario de datos escasos
AUC-ROC
F1-Score
Métrica
1.00
0.95
0.90
0.85
0.80
0.75
Umbral referencia 0.90
0.9303
0.8209
0.9277
0.8357
0.9195
0.8482
0.8828
0.8224
0.8645
0.8021
★ SimCLR es el MEJOR método con datos escasos (sin etiquetas en preentrenamiento)
SimCLR (nuestro) ★
CNN desde cero
ResNet-50 Supervisado
SVM + ResNet
RF + ResNet
Alejandro Cuevas · Iria Lozano · Javier Saguar — PASD, UPM


Comparativa AUC-ROC – SimCLR vs Métodos Supervisados
484 pacientes — dataset completo
MEJOR
Con suficientes datos, la supervisión directa supera al aprendizaje contrastivo. SimCLR requirió ~600 min vs ~57 min de ResNet supervisada.
Métrica
1.00
0.95
0.90
0.85
0.80
0.75
Umbral referencia 0.90
0.9798
0.9333
0.9725
0.9180
0.9431
0.8764
0.9333
0.8636
0.8945
0.8168
★ mejor con 20 pac.
CNN desde cero
ResNet-50 Supervisado
SVM + ResNet
RF + ResNet
SimCLR (nuestro)
AUC-ROC
F1-Score
Alejandro Cuevas · Iria Lozano · Javier Saguar — PASD, UPM

La comparativa con métodos supervisados revela el hallazgo central del trabajo:

Método	AUC (20 pac.)	AUC (484 pac.)	Etiquetas
SimCLR (nuestro)	**0.9303**	0.8945	Solo fine-tuning
ResNet-50 Supervisado	0.9195	0.9725	Todas
CNN desde cero	0.9277	0.9798	Todas
SVM + ResNet	0.8828	0.9431	Todas
RF + ResNet	0.8645	0.9333	Todas

Con 20 pacientes, SimCLR es el mejor método, superando a todos los supervisados sin haber usado ninguna etiqueta durante el preentrenamiento. Con 484 pacientes los métodos supervisados ganan — lo que define el escenario óptimo de cada enfoque.



Discusión

Los resultados demuestran la viabilidad del aprendizaje contrastivo para detectar biomarcadores visuales en RM cerebral multimodal, y más importante, definen con precisión cuándo usarlo.

SimCLR es el método óptimo con datos escasos. Con 20 pacientes etiquetados obtiene AUC 0.93, superando a ResNet supervisada (0.92) y CNN desde cero (0.93) que necesitan todas las etiquetas. En el contexto clínico real, donde etiquetar volúmenes NIfTI requiere radiólogos especializados y horas de trabajo por caso, esta ventaja es decisiva.

Con suficientes datos, la supervisión directa gana. Con 484 pacientes la CNN desde cero alcanza AUC 0.98 frente al 0.89 de SimCLR. Resulta llamativo que la CNN sin preentrenamiento supere a ResNet supervisada: una posible explicación es que los sesgos

de ImageNet dificultan la adaptación al dominio médico, mientras que la CNN aprende libremente la morfología cerebral.

El análisis de cortes centrales (Z=60-100) reveló un resultado contraintuitivo: filtrar los cortes más informativos empeora el AUC (0.89→0.78) debido al desbalance extremo resultante (86% con tumor). Esto confirma que la heterogeneidad del dataset completo, aunque añade dificultad, es metodológicamente necesaria para un entrenamiento generalizable.

Como trabajo futuro: VICReg [3] o BYOL como alternativas más estables, ViT [7] para capturar dependencias globales, aumentaciones específicas para RM, y segmentación con cabeza U-Net sobre el encoder preentrenado.

Conclusiones

El aprendizaje contrastivo (SimCLR) es el método óptimo para la detección de biomarcadores en RM cerebrales cuando los datos etiquetados son escasos: con 20 pacientes obtiene AUC 0.93, superando a todos los métodos supervisados. Con datos abundantes (484 pacientes), la supervisión directa resulta más eficiente. La validación estadística con 5 runs (AUC 0.9068 ± 0.0276) confirma la robustez del método. El split correcto por paciente es imprescindible para evitar data leakage y obtener estimaciones fiables de generalización.

Referencias

[1] Chen et al. (2020). *SimCLR*. ICML. https://arxiv.org/abs/2002.05709

[2] He et al. (2020). *MoCo*. CVPR. https://arxiv.org/abs/1911.05722

[3] Bardes et al. (2022). *VICReg*. ICLR. https://arxiv.org/abs/2105.04906

[4] Menze et al. (2015). *BRATS*. IEEE TMI. https://doi.org/10.1109/TMI.2014.2377694

[5] Bakas et al. (2017). *TCGA glioma MRI*. Scientific Data. https://doi.org/10.1038/sdata.2017.117

[6] He et al. (2016). *ResNet*. CVPR. https://arxiv.org/abs/1512.03385

[7] Dosovitskiy et al. (2021). *ViT*. ICLR. https://arxiv.org/abs/2010.11929

[8] Azizi et al. (2021). *SSL en imagen médica*. ICCV. https://arxiv.org/abs/2101.05224

[9] Chaitanya et al. (2020). *Contrastive Learning para segmentación*. NeurIPS. https://arxiv.org/abs/2006.10511

[10] Van der Maaten & Hinton (2008). *t-SNE*. JMLR. https://jmlr.org/papers/v9/vandermaaten08a.html

---

Materiales

- Dataset BRATS: http://medicaldecathlon.com/
- Notebook del proyecto: [enlace Drive]
- SimCLR (Google Research): https://github.com/google-research/simclr
- solo-learn (PyTorch): https://github.com/vturrisi/solo-learn
- PyTorch: https://pytorch.org/
- nibabel: https://nipy.org/nibabel/

COSAS A TENER EN CUENTA

¿Por qué usamos solo un dataset? El de BRATS es un dataset conocido de una competiicón para ver quien obtenia mejor resultado. Dataset conocido, muy completo, 484 pacientes, 4 modalidades de tomografía.

Poner resultado final en la descripción del proyecto

Porque es aprendizaje contrastivo.

Un split más correcto, más interesante hacer un 70/30 porque tenemos muy pocos pacientes para la valoración.